



Projet de Machine Learning

Sujet 3 :

LLM et applications en Finance




Groupe 10 : Romain Bajard, Ewen Dévé, Charlotte Droin, Bertrand Lecoeur



Sommaire

- 1 État de l'art des Large Language Models
- 2 Comment un LLM peut-il être utilisé pour analyser, synthétiser et répondre à des questions sur des textes de finance ?


ÉTAT DE L'ART DES LARGE LANGUAGE MODELS



Évolution

Des réseaux de neurones aux LLM


Les LLM ne sont pas une rupture totale ; ils ont émergé quand les transformers sont devenus l'architecture dominante du traitement du langage.



Comment fonctionne un LLM ?

Entraînement d'un Large Language Model

Découpage en 7 étapes, de l'apprentissage du langage à la mise en oeuvre d'un système LLM opérationnel



Comment fonctionne un LLM ?

Deux briques décisives : instruction tuning et RLHF

Elles expliquent pourquoi un modèle pré-entraîné devient un assistant conversationnel utilisable.

INSTRUCTION TUNING


Problème : le modèle brut (pré-entraîné) n'est pas optimisé pour suivre des instructions.

Méthode : on crée (ou collecte) des paires "instruction / réponse idéale".

Exemple : "Explique-moi le rôle de la banque centrale en 2 phrases" → "La banque centrale maîtrise l'inflation etc."

On affine le modèle pour qu'il apprenne à générer des réponses cohérentes et utiles lorsqu'on lui donne des instructions explicites.

Résultat : un modèle plus obéissant, apparition d'une conversation plus fluide.



RLHF : REINFORCEMENT LEARNING FROM HUMAN FEEDBACK

But : aligner le comportement du modèle sur les préférences humaines (comportement "agréable").

Mécanisme : des annotateurs humains comparent deux réponses du modèle à une même instruction et indiquent laquelle est la meilleure.

Optimisation par renforcement : utilisation du score comme fonction de pertes.

Effet : réduit les réponses inutiles ou hors consigne.

Comment fonctionne un LLM ?

Distillation vers des modèles plus petits et Mixture of experts


Deux leviers supplémentaires : compresser l'intelligence d'un grand LLM dans un modèle plus léger (distillation) et augmenter la capacité du modèle sans activer tous les paramètres à chaque token (MoE).

DISTILLATION

Objectif : réduire la taille du modèle et accélérer l'inférence, tout en gardant une performance acceptable

Procédé : entraîner un petit modèle (student) à reproduire les sorties d'un grand modèle (teacher), puis minimiser l'écart entre leurs distributions de prédiction.

Bénéfice : coûts d'inférence plus faibles, moins de mémoire GPU, déploiement facilité.



MIXTURE OF EXPERTS (MOE)

Concept : diviser le réseau en plusieurs "experts" spécialisés, activés selectivement.

Avantages : évolutivité, car chaque token ne mobilise qu'un sous-ensemble d'experts ; flexibilité avec des experts dédiés au code, aux maths ou au texte.

Défis : synchronisation entre experts, communication et load balancing pour éviter la saturation d'un seul expert.

Au delà du modèle : function calling et RAG


Une dernière couche pour faire fonctionner un LLM

Booster le contexte et relier le LLM à des outils ou à une base de documentation

ACTIONS (FUNCTION CALLING)

Le LLM ne répond plus seulement avec du texte : il analyse la requête utilisateur et peut décider d'appeler une fonction externe, générer des paramètres, récupérer le résultat de la fonction puis l'intégrer dans sa réponse finale.

Construction d'agents autonomes capables d'actions complexes.




RAG (RETRIEVAL-AUGMENTED GENERATION)

Le RAG combine la génération de LLM avec une recherche dans une base de connaissances externe :

- Base de connaissances (documents, PDF, etc.)
- Indexation vectorielle (transformation en embeddings)
- Moteur de recherche sémantique
- Contexte injecté dans les consignes

Avantages : connaissances à jour et transparence par citation des sources



Les limites qui façonnent encore l'état de l'art des LLM

Avant de parler finance

Le problème de l'alignement d'un LLM consiste à faire en sorte qu'un modèle respecte les intentions et les valeurs humaines, au lieu d'optimiser aveuglément sa fonction-objectif.

1

Corrélation ≠ causalité

Un modèle statistique peut détecter des régularités sans comprendre les vraies causes.

Défi : intégrer le raisonnement causal dans les modèles d'IA.

2

Hallucinations

Un LLM peut produire une réponse très plausible tout en inventant un fait, une source ou un chiffre.

3

Biais

Les données d'entraînement peuvent amplifier des stéréotypes ou créer des inégalités entre sous-groupes de données.

4

Alignement & sécurité

Il faut imposer des garde-fous, des politiques et du feedback humain pour rapprocher le modèle des intentions humaines (éthique, législation).

COMMENT UN LLM PEUT-IL ÊTRE UTILISÉ POUR ANALYSER, SYNTHÉTISER ET RÉPONDRE À DES QUESTIONS SUR DES TEXTES DE FINANCE ?



Exemple 1 : Quantifier l'implicite lors des sessions Questions/Réponses entre analystes financiers et dirigeants

→ Analyse des réponses des dirigeants lors des **Earnings Calls**

→ **But: Détecter un changement de ton/ vocabulaire défensif/ niveau d'esquive**

Script Python utilisant le LLM pour extraire ces signaux faibles et textuels

Grâce à un modèle LLM qu'on nourrit → **Anticiper dégradance gouvernance avant chute des prix**

→ On choisit le LLM comme un **Feature Extractor** (Extracteur de caractéristiques sémantiques)

Avant (Texte brut)	Après (Score LLM)
“La situation économique actuelle est complexe, nous préférons donc attendre le prochain trimestre avant de donner des prévisions précises”	Score d'esquive: 8/10 Tonalité défensive: Elevée

Pipeline Python



Préparation de la donnée

- Nettoyage Retranscriptions
- Ciblage des réponses
- Pandas (charger fichiers textes), regex (expressions régulières pour nettoyer de longs fichiers textes)

Interaction avec le LLM

- Via API (librairie openai)
- Rédaction d'un prompt très strict (Prompt Engineering structuré)
- Contrainte: format JSON (librairie Pydantic) pour scores entiers

Vers le Machine Learning

- Scores générés par le LLM deviennent nouvelles colonnes dans DataFrame
- Croisement de ces nouvelles notes avec le ratio financier classique
- Découpage des données (Train/ Test) et entraînement d'un modèle (Random Forest) pour prédire risque de baisse de notation

Exemple 2 : BloombergGPT


Le premier LLM spécialisé pour la Finance

Concept : 50B paramètres entraîné spécifiquement sur un corpus de données financières (363B de tokens) combiné à un corpus généraliste (345B de tokens)	Objectif : Dépasser les modèles généralistes sur les tâches de Traitement du Langage Naturel Financier (FiNLP) tout en conservant d'excellentes capacités en langage général.
Méthodologie : Utilisation des données propriétaires de Bloomberg collectées sur 40 ans.	Avantages : Performance supérieure sur les benchmarks financiers (comme FiQA SA) et meilleure compréhension des entités nommées (tickers, entreprises) par rapport à GPT-4 ou Llama.
Architecture : Basé sur une architecture de type Transformer "Decoder-only" (similaire à GPT), mais optimisé pour traiter le vocabulaire et les nuances du langage financier.	Limites : Malgré sa spécialisation, le modèle peut encore générer des hallucinations factuelles et reste un modèle "fermé" (propriétaire), limitant son auditabilité par la communauté académique.

Exemple 3 : Credit Scoring Narratif

Le LLM comme analyste de crédit

Analyse de données qualitatives : “**Soft Information**” (stratégie, réputation et la cohérence d’un projet à travers ses texte).



Avantages :

Inclusion financière : Permet de mieux évaluer les startups ou PME qui ont peu d'historique comptable mais un projet solide.

Gain de temps : Lecture et synthèse instantanée de centaines de pages de documents de prêt.

Risque & Limite :

Le biais algorithmique (le modèle peut hériter des préjugés des données d'entraînement)

Exemple 4 : Identifier des anomalies et des fraudes

- Les LLM permettent d'analyser de grandes quantités de données financières
- Identification de schémas inhabituels indiquant une activité suspecte
- Analyse en temps réel des transactions pour détecter des anomalies
- Exemples : fraude, arnaques, manipulation de comptes
- Réduction des faux positifs grâce à une meilleure compréhension des comportements
- Adaptation aux nouvelles formes de fraude grâce à l'apprentissage continu

CONCLUSION

- Les LLM permettent d'exploiter des données textuelles en finance
- Transformation de la “soft information” en variables quantitatives
- Utilisation comme feature extractor dans un pipeline ML
- Applications : earnings calls, analyse financière, scoring crédit, identifier des fraudes
- Limites : dépendance aux données, biais, hallucinations, coût d'hébergement

Merci pour votre écoute